BÁO CÁO KỸ THUẬT – UEBA BENCHMARK

Benchmark Isolation Forest, LOF, One-Class SVM trên log xác thực Windows (Event 4624/4625)

Thành viên: Lâm Vũ – Đinh Xuân Hiệp | Báo cáo tổng tuần 1–6, ngày 15/10/2026

Chương trình: Thực chiến AI, đề tài thực tập 6 tuần
Phiên bản: 1.0, ngày 15/10/2026. Mã nguồn và số liệu ở nhánh `feature/target-rate-1pct`, commit `ee0d52f`
Căn cứ: `docs/Tong quan de tai ueba.md` (gọi tắt là *đề cương*)

Báo cáo này gom kết quả của tuần 1–5 thành một tài liệu độc lập. Người đọc không cần mở các báo cáo tuần để hiểu phương pháp và kết quả; đường dẫn tới số liệu gốc được ghi ở cuối mỗi mục. Mọi số liệu định lượng tính trên nhãn tổng hợp (tấn công được tiêm vào log thật) nên là cận trên lạc quan của hiệu năng trên tấn công thật.

Mục lục

Tóm tắt **1**

1. Giới thiệu **1**
1.1. Bối cảnh . . . 1
1.2. Mục tiêu và câu hỏi . . . 2
1.3. Phạm vi . . . 2
1.4. Những điểm khác đề cương . . . 2

2. Dữ liệu **3**
2.1. Nguồn . . . 3
2.2. Phân loại tài khoản . . . 3
2.3. Chất lượng dữ liệu và các quyết định làm sạch . . . 3
2.4. Từ log tới ma trận đặc trưng . . . 4
2.5. Nhịp theo thời gian . . . 4

3. Phương pháp **5**
3.1. Đặc trưng . . . 5
3.2. Mô hình . . . 5
3.3. Mốc tham chiếu . . . 6
3.4. Thiết kế đánh giá . . . 6

4. Kết quả **7**
4.1. Lưới cấu hình trên dev (22 đặc trưng) . . . 7
4.2. Benchmark cuối trên test . . . 8
4.3. Đường PR và độ nhạy contamination . . . 9
4.4. Theo loại tấn công . . . 10
4.5. Chi phí tính toán . . . 12

5. Phân tích **12**
5.1. Vì sao OCSVM vượt LOF . . . 12
5.2. Scaler: lựa chọn "an toàn" theo sách giáo khoa có thể sai . . . 12
5.3. Chọn đặc trưng: từ 41 xuống 22 . . . 13
5.4. Cửa sổ lịch sử 7 / 14 / 21 ngày . . . 15
5.5. Ba kịch bản bị bắt kém: off_hours, password_spraying, dormant_wakeup . . . 15
5.6. Độ ổn định . . . 15
5.7. Mức lạc quan của kết quả . . . 16

6. Đánh giá định tính: review thủ công top 50 **16**

6.1. Thiết lập 16
6.2. Trạng thái 16

7. Hạn chế đã biết **17**

8. Khuyến nghị triển khai **17**
8.1. Kiến trúc phân luồng theo loại tài khoản 17
8.2. Cấu hình mô hình 17
8.3. Ngân sách cảnh báo và chi phí vận hành 17
8.4. Vận hành và theo dõi 18

9. Tái lập và vận hành **18**
9.1. Môi trường 18
9.2. Một lệnh 18
9.3. Từng bước 19
9.4. Mô hình cho demo 19
9.5. Trạng thái kiểm chứng 19

10. Đối chiếu tiêu chí hoàn thành (đề cương mục 4.1) **19**

Phụ lục A: 22 đặc trưng của benchmark cuối **20**

Phụ lục B: bản đồ số liệu **21**

Tóm tắt

1. **Bài toán.** Phát hiện hành vi bất thường của tài khoản người dùng từ log đăng nhập Windows (4624 thành công, 4625 thất bại) của bộ LANL Unified Host, 60 ngày, khoảng 943 triệu sự kiện sau làm sạch. Đơn vị phân tích là một dòng (tài khoản, ngày). Không có nhãn thật, nên hiệu năng được đo bằng 6 kịch bản tấn công tiêm vào log.
2. **Đặc trưng.** 41 đặc trưng hành vi được sinh theo một không gian tổ hợp có kiểm soát và lọc qua phễu 2 vòng. Phân tích SHAP và thí nghiệm loại bỏ trên dev rút gọn còn 22 đặc trưng cho benchmark cuối.
3. **Thiết kế đánh giá.** Chia theo thời gian: train ngày 1–42, test ngày 43–60; chọn cấu hình trên khối dev (ngày 36–42, fit 1–35) nằm trong train. Mỗi run tiêm đúng 1% số dòng User. 5 seed, báo cáo trung bình ± độ lệch chuẩn.
4. **Kết quả chính (test, 22 đặc trưng, 5 seed).** One-Class SVM tốt nhất: recall top-100 cảnh báo/ngày 0,336 ± 0,070, PR-AUC 0,175 ± 0,048, gấp khoảng 3,4 lần recall và 7 lần PR-AUC của luật "số lần thất bại ≥ 5", gấp 17 lần ngẫu nhiên về PR-AUC. Thứ hạng ổn định: OCSVM > IF > LOF > z-score > các luật > ngẫu nhiên.
5. **Phát hiện quan trọng.**
   - Phát hiện tốt brute-force, đổi loại logon, bùng nổ máy trạm mới; bắt kém ba loại: dời hoạt động sang ban đêm, rải mật khẩu (password spraying) và tài khoản ngủ đông thức dậy, do đặc trưng chỉ tính theo từng tài khoản trong từng ngày.
   - Chọn scaler quyết định mô hình dựa trên khoảng cách: đổi RobustScaler sang StandardScaler nâng PR-AUC OCSVM từ 0,03 lên 0,24 trên dev.
   - Bớt đặc trưng làm mô hình tốt hơn: từ 41 xuống 22 đặc trưng, recall IF tăng 0,16 → 0,24 trên test.
   - Cấu hình OCSVM tốt nhất trên dev (`g01`) kém ổn định trên test; cấu hình `nc1000` ổn định hơn và được khuyến nghị khi triển khai.
   - LOF dùng chỉ mục láng giềng xấp xỉ đa luồng nên không tất định ở mức từng lần fit.
6. **Khuyến nghị.** Triển khai OCSVM cho phân khúc User với ngân sách khoảng 100 cảnh báo/ngày, chạy song song một luật riêng cho dò/rải mật khẩu; tài khoản dịch vụ, hệ thống và quản trị dùng luật và danh sách trắng thay cho học máy (mục 8).

1. Giới thiệu

1.1. Bối cảnh

UEBA (User and Entity Behavior Analytics) phát hiện tấn công bằng cách học hành vi bình thường của tài khoản rồi cảnh báo khi hành vi lệch đi. Log đăng nhập Windows là nguồn dữ liệu phổ biến nhất cho bài toán này: mỗi lần đăng nhập thành công sinh Event 4624, mỗi lần thất bại sinh Event 4625. Các tấn công như dò mật khẩu, chiếm đoạt tài khoản hay di chuyển ngang đều để lại dấu vết trong hai loại sự kiện này.

Ba thuật toán phát hiện bất thường không giám sát thường được dùng làm mốc là Isolation Forest (IF), Local Outlier Factor (LOF) và One-Class SVM (OCSVM). Đề tài đặt câu hỏi: trên log xác thực thật, với một quy trình đánh giá chặt chẽ, ba mô hình này hơn một luật ngưỡng đơn giản bao nhiêu, và mỗi mô hình bắt được loại tấn công nào?

1.2. Mục tiêu và câu hỏi

#	Câu hỏi	Trả lời ở
Q1	Mô hình nào xếp hạng tài khoản bất thường tốt nhất trong ngân sách cảnh báo thực tế?	Mục 4.2
Q2	Mô hình có vượt luật ngưỡng số lần thất bại và chấm điểm ngẫu nhiên không?	Mục 4.2
Q3	Mỗi mô hình bắt tốt loại tấn công nào, bỏ sót loại nào, vì sao?	Mục 4.4, 5.5
Q4	Đặc trưng nào đóng góp, đặc trưng nào gây nhiễu?	Mục 5.3
Q5	Kết quả có ổn định qua seed, qua lần chạy lại và nhạy với tham số đến đâu?	Mục 4.3, 5.6

1.3. Phạm vi

- **Trong phạm vi:** log 4624/4625 đã ẩn danh của LANL; ma trận (tài khoản × ngày); 3 mô hình + 4 mốc tham chiếu; nhãn tổng hợp 6 kịch bản; đánh giá phân khúc tài khoản người dùng (User).
- Ngoài phạm vi (đề cương mục 2.2): mô hình học sâu, phát hiện theo thời gian thực, tích hợp SIEM, nhãn tấn công thật.

1.4. Những điểm khác đề cương

Đề cương cho phép điều chỉnh khi có lý do. Bảng dưới liệt kê các điều chỉnh để người đọc không phải tự đối chiếu.

Hạng mục	Đề cương	Báo cáo này	Lý do
LOF	`LocalOutlierFactor(novelty=True)` của scikit-learn	LOF tính trên láng giềng xấp xỉ HNSW (thư viện `hnswlib`)	LOF chính xác không chạy được trên khoảng 315.000 dòng User với nhiều cấu hình, nên tuần 3 chỉ fit trên mẫu con 20.000–50.000 dòng. Khi đó kết quả phụ thuộc vào mẫu được lấy: Top-20 qua 3 seed trùng trung bình 72% với mẫu 50.000 dòng (báo cáo tuần 3) nhưng chỉ 3% với mẫu 20.000 dòng (`reports/week3/tom_tat_tuan3.md`). HNSW cho phép fit trên toàn bộ dữ liệu train nên bỏ được phụ thuộc này
One-Class SVM	`OneClassSVM(kernel="rbf")`	Nhân RBF xấp xỉ bằng Nystroem, rồi `SGDOneClassSVM`	Bản gốc của scikit-learn có thời gian chạy tăng theo bậc 2–3 của số dòng
Chỉ số chính	PR-AUC	Recall top-100 cảnh báo/ngày. PR-AUC vẫn có trong mọi bảng	Khớp với việc SOC chỉ xem được một số cảnh báo cố định mỗi ngày, và so được giữa các loại tấn công (mục 3.4.3)

Hạng mục	Đề cương	Báo cáo này	Lý do
Chia tập	Train / test theo thời gian	Thêm khối dev (ngày 36–42) nằm trong train	Chọn cấu hình và đặc trưng mà không dùng nhãn của test (một ngoại lệ ở mục 5.3.3)

Vì hai thuật toán là bản xấp xỉ, mọi kết luận về "LOF" và "OCSVM" trong báo cáo là kết luận về các bản xấp xỉ này (mục 7, hạn chế 5).

2. Dữ liệu

2.1. Nguồn

Bộ LANL Unified Host and Network Dataset: log Windows Security của mạng doanh nghiệp Los Alamos, đã ẩn danh, 60 ngày (bộ gốc dài 90 ngày, mỗi ngày khoảng 400 triệu bản ghi đủ loại; đề tài dùng 60 ngày). Dự án dùng hai loại sự kiện:

Sự kiện	Ý nghĩa	Ví dụ ngày 1
4624	Đăng nhập thành công	14,1 triệu
4625	Đăng nhập thất bại	0,34 triệu (2,3%)

Mỗi sự kiện có 21 trường, chia 6 nhóm: thời gian (`Time`, số giây tính từ đầu bộ dữ liệu), sự kiện (`EventID`), danh tính (`UserName`, `DomainName`, `LogonID`, `Subject*`), máy (`LogHost`, `Source`, `Destination`), xác thực (`LogonType`, `AuthenticationPackage`, `FailureReason`, `Status`, ...) và tiến trình (`Process*`). Ý nghĩa từng trường ở `docs/data_dictionary.md`.

Quy mô sau làm sạch: khoảng 943 triệu sự kiện; ma trận đặc trưng có 1.055.283 dòng (tài khoản, ngày).

2.2. Phân loại tài khoản

Khoá của một tài khoản là cặp (`DomainName`, `UserName`). Tài khoản được chia 5 loại theo tên:

Loại	Dòng train (ngày 1–42)	Dòng test (ngày 43–60)	Số tài khoản (60 ngày)	Tỷ lệ sự kiện
Machine (tên kết thúc `$`)	404.907	180.092	13.497	45%
User	314.847	152.740	18.003	36%
Admin (`Administrator`)	1.371	630	825	3%
Service (`AppService`, `Scanner`, ...)	317	137	10	12%
System (`nt authority\{}...`)	170	72	6	3%

Quyết định: đánh giá chỉ trên User vì (1) đây là đối tượng tấn công chiếm đoạt tài khoản nhắm tới; (2) Admin, Service, System quá ít thực thể để học máy có nghĩa (ví dụ System có 6 tài khoản, ít hơn số láng giềng $k = 20$ của LOF) và hành vi của chúng gần như tất định, phù hợp với luật hơn; (3) tài khoản Machine không được tiêm. Chi tiết: `docs/reports/thong_ke_loai_tai_khoan.md`.

2.3. Chất lượng dữ liệu và các quyết định làm sạch

Khảo sát chất lượng (tuần 1, notebook `01_data_quality_single_day.ipynb` và `02`–`06`) dẫn tới 5 quyết định, cài đặt trong `src/data/cleaner.py` và có unit test (`tests/test_cleaner.py`):

#	Vấn đề phát hiện	Quyết định	Lý do
1	`LogonTypeDescription` thiếu ở vài bản ghi 4624	Điền theo bảng ánh xạ chuẩn của Microsoft từ `LogonType`	Quan hệ 1–1, không cần đoán
2	Ở 4624, `Process*` thiếu 92%, `Subject*` thiếu 99,9%; `Status`, `Destination`, `ServiceName`, `ParentProcess*` trống hoàn toàn ở cả hai sự kiện	Bỏ cột (21 → 11 cột)	Không mang thông tin; giữ lại chỉ tốn bộ nhớ
3	`Source`, `LogonID`, `DomainName` có giá trị thiếu (ngày 16: `Source` thiếu 24% ở 4624 và 32% ở 4625; `LogonID` thiếu 49% ở 4625)	Điền nhãn `"Unknown"`, chuẩn hoá `DomainName` về chữ thường	Giữ đủ số dòng và trục thời gian; thiếu `Source` vẫn là thông tin (có đặc trưng `missing_source_ratio`)
4	Bản ghi trùng hoàn toàn (ngày 1: 2,1%)	Xoá trùng tuyệt đối	Tránh thổi phồng số sự kiện
5	Lệch giờ mùa hè từ ngày 42	Trừ 3.600 giây cho ngày ≥ 42	Đưa 60 ngày về cùng trục 24 giờ, quan trọng cho đặc trưng ngoài giờ

Nhật ký và số liệu kiểm chứng: `docs/nhat_ky_trien_khai_pipeline.md`.

2.4. Từ log tới ma trận đặc trưng

```
data/interim/ (log theo ngày, parquet)
  +- clean  (src/data/cleaner.py)          → data/cleaned/   11 cột, đã khử trùng, đã chỉnh giờ
     +- features (src/features/extractor.py, template_engine.py, history.py)
                                            → data/features/raw/  ma trận (tài khoản × ngày)
        +- preprocessor                     → data/processed/feature_matrix_processed.parquet
```

Mỗi bước chạy bằng `python main.py -stage <clean|features|...>`, có ghi log và kiểm tra lược đồ (`FeatureSchema.validate_features`). Đặc trưng lịch sử của ngày t chỉ dùng dữ liệu các ngày ≤ t−1.

2.5. Nhịp theo thời gian

`Time` không phải ngày giờ lịch mà là số giây tính từ đầu bộ dữ liệu: ngày 1 có `Time` từ 1 đến 86.399, ngày d gồm các sự kiện có `Time` trong khoảng $[(d-1)\cdot 86.400, d\cdot 86.400)$. Giờ trong ngày được tính bằng `(Time mod 86.400) div 3.600`. Cách tính này giả định `Time = 0` là nửa đêm giờ địa phương. Bảng dưới kiểm tra giả định đó và các nhịp khác của dữ liệu.

Bảng 2.1: Nhịp theo thời gian của 60 ngày dữ liệu

Câu hỏi	Kết quả	Kết luận
Có chu kỳ 7 ngày không?	Hệ số tự tương quan của lưu lượng ngày ở độ trễ 7 là 0,58, cao nhất trong các độ trễ 1–14. Riêng thứ tự ngày trong tuần giải thích 67% biến động của lưu lượng	Có
Có "cuối tuần" không?	2 trong 7 ngày có lưu lượng thấp hơn 29% và số tài khoản hoạt động thấp hơn 31%, lặp lại ở 87,5% số tuần (16 ngày: 6, 7, 13, 14, …, 55, 56)	Có
Ban đêm có vắng hơn ban ngày không?	Ngày thường, 0h–5h trung bình 553.600 sự kiện 4624/giờ, thấp hơn 37% so với 9h–15h (877.500/giờ). Thấp nhất lúc 4h, cao nhất lúc 9h. Cuối tuần gần như phẳng	Có. Cách tính giờ khớp với giờ địa phương
Hành vi có trôi theo thời gian không?	Tương quan hạng giữa ngày và trung bình trượt 7 ngày: khối lượng 0,12; tỷ lệ thất bại −0,38; tỷ lệ ngoài giờ 0,28 (ngưỡng 0,3)	Tỷ lệ thất bại có trôi

Hệ quả cho thiết kế:

1. Cửa sổ lịch sử 7 ngày chứa đúng một chu kỳ tuần, nên khi so ngày t với 7 ngày trước, cuối tuần không bị coi là bất thường.
2. **Dữ liệu không có ngày lịch.** "Cuối tuần" ở đây là hai ngày có lưu lượng thấp nhất trong chu kỳ, chưa đối chiếu được với thứ Bảy và Chủ nhật thật.
3. **Khung ngoài giờ (18h–7h) rộng.** Khung này dài 14/24 giờ và chiếm 51,6% tổng số sự kiện. Ngày thường, lưu lượng lúc 7h đã bằng 90% giờ cao điểm mà vẫn bị tính là ngoài giờ. Hệ quả cho kịch bản off_hours được phân tích ở mục 5.5.
4. Có trôi nhẹ, nên chia tập theo thời gian (mục 3.4.1) cho kết quả gần với lúc triển khai thật hơn chia ngẫu nhiên.

Nguồn: `reports/week2/temporal_stability_check.md` · `docs/feature_engineering/tables/hourly_rhythm_summary.csv` · `docs/feature_engineering/figures/temporal_hourly_rhythm.png`

3. Phương pháp

3.1. Đặc trưng

3.1.1. Quy trình xây bộ 41 đặc trưng

Bộ đặc trưng đi qua 4 phiên bản: 18 ở tuần 2 (16 tính trong ngày, 2 lịch sử) → 24 ở tuần 3 → 39 → 41 ở tuần 4. Phiên bản v4 dùng không gian tổ hợp 4 trục để sinh ứng viên một cách có hệ thống thay vì liệt kê theo cảm tính:

Trục	Giá trị
Phép đo (14)	đếm, đếm phân biệt, tỷ phần, độ đều, fan-out, độ mới, Jaccard, độ dịch phân bố, chênh so với trung bình, z so với nhóm, …
Đối tượng (4)	mọi sự kiện, thất bại, thành công, ban đêm
Chiều (8)	sự kiện, Source, LogHost, cặp (Source, LogHost), giờ, loại logon, gói xác thực, lý do thất bại
Cửa sổ (7)	1 ngày; khung 5/15/60 phút; 7/14 ngày trước; toàn lịch sử

3.136 tổ hợp → lọc ngữ pháp còn 471 → vòng 1 lọc bằng lập luận an ninh (trùng, không gắn kịch bản, khó diễn giải, biến thể dư) còn 78 → vòng 2 lọc bằng số đo trên dữ liệu thật theo 4 cổng:

Cổng	Điều kiện	Còn lại
E – rò rỉ thời gian	Giá trị không đổi khi cắt dữ liệu ở t−1	78
B – có thông tin	NULL $\leq$ 50%, không hằng số $>$ 99%	68
A – không trùng	max(|Pearson|, |Spearman|) $<$ 0,85 với các biến đã chọn	29
C – phân tách kịch bản	AUC $\geq$ 0,70 với ít nhất một kịch bản	26

Chốt 15 biến mới (VIF $\leq$ 10) → 39 core; v4.1 thêm 2 biến dự bị → 41 core, chia 8 nhóm theo nghĩa: volume (3), failure (6), time (8), rhythm (4), logon_type (6), fanout (6), novelty (5), context (3). Mỗi đặc trưng có tên, công thức, kiểu dữ liệu và diễn giải trong `configs/feature_schema.yaml` và bảng ở README mục 4. Chi tiết phễu: `docs/reports/bao_cao_bo_dac_trung_v4.md`.

Lưu ý phương pháp: cổng C dùng nhãn tiêm, nên nó chỉ chứng minh đặc trưng phản ứng đúng chiều với kịch bản, không chứng minh đặc trưng làm mô hình tốt hơn. Câu hỏi sau được trả lời bằng thí nghiệm loại bỏ ở mục 5.3.

3.1.2. Bộ 22 đặc trưng của benchmark cuối

Trên khối dev, SHAP cho thấy nhóm rhythm (nhịp thời gian giữa các sự kiện) ít giúp bắt nạn nhân nhưng là nguồn báo nhầm chính của OCSVM, và 18 đặc trưng có đóng góp dưới mức chia đều ở mọi mô hình, mọi run. Bỏ 4 đặc trưng rhythm và 18 đặc trưng SHAP thấp (3 trùng nhau, tổng bỏ 19) cho 22 đặc trưng (danh sách ở Phụ lục A). Quy trình chọn và kiểm tra trên test ở mục 5.3. Bộ 22 được áp dụng qua `drop_features` trong cấu hình lưới; lược đồ vẫn giữ đủ 41 core.

3.2. Mô hình

Ba mô hình và bốn mốc tham chiếu dùng chung một giao diện (`src/models/base.py`, `pipeline.py`): đặc trưng → điền thiếu bằng median → scaler → mô hình, mọi bước chỉ fit trên train của phân khúc; điểm càng cao càng bất thường; ngưỡng cảnh báo = phân vị (1 − contamination) của điểm train (không dùng nhãn).

Mô hình	Cài đặt	Lý do
Isolation Forest	scikit-learn `IsolationForest`, fit toàn bộ train	Chuẩn, nhanh, không phụ thuộc thang đo
LOF	LOF trên láng giềng xấp xỉ HNSW (hnswlib), chỉ mục trên các dòng duy nhất	LOF chính xác không chạy được trên 315.000 dòng × nhiều cấu hình; khử trùng tránh k-distance = 0 (điểm LOF $\approx 10^{10}$)
One-Class SVM	Nhân RBF xấp xỉ Nystroem + `SGDOneClassSVM`	OCSVM chính xác có độ phức tạp bậc 2–3 theo số mẫu; `nu` = contamination

Tham số mặc định ở `configs/model_params.yaml`; các cấu hình của lưới ở `configs/benchmark_grid_dev_22f.yaml`.

3.3. Mốc tham chiếu

Mốc	Điểm số	Vai trò
Ngẫu nhiên	Băm tất định theo dòng	Sàn hiệu năng (đề cương 5.3)
Luật số lần thất bại ≥ 5	Số lần thất bại trong ngày; ngưỡng cố định L = 5 ước lượng từ log train (trung vị số lần sai trước khi bị khoá)	Thứ đội vận hành làm được trong 10 phút (đề cương 5.3)
Luật 6 điều kiện	Tỷ lệ luật thoả: thất bại, khoá, NTLM, ngoài giờ, cùng giây, từ xa	Luật phong phú hơn
Z-score bền vững	max |z| (median, MAD) trên các đặc trưng	Đo giá trị của mô hình hoá đa biến

Z-score lấy max trên nhiều đặc trưng thay vì một đặc trưng như đề cương mô tả, vì không có một đặc trưng đơn lẻ nào đại diện cho cả 6 kịch bản. Chi tiết: `reports/week4/baselines_report.md`.

3.4. Thiết kế đánh giá

3.4.1. Chia tập theo thời gian

Khối	Fit	Chấm	Dùng để
Dev	ngày 1–35	ngày 36–42	Chọn cấu hình, chọn đặc trưng, SHAP
Test	ngày 1–42 (70% thời gian)	ngày 43–60 (30%)	Báo cáo kết quả, chạy với cấu hình đã chốt

Dev nằm hoàn toàn trong train, nên test không tham gia bất kỳ lựa chọn nào (một ngoại lệ được ghi ở mục 5.3).

3.4.2. Nhãn tổng hợp: 6 kịch bản tấn công

Bộ tiêm (`src/injection/`) chèn sự kiện vào log, sau đó toàn bộ đặc trưng được tính lại, kể cả đặc trưng lịch sử 7 ngày. Nguyên tắc: không bịa giá trị trường, mọi sự kiện tiêm là bản sao một sự kiện thật của train (của chính nạn nhân nếu có); hồ sơ hành vi chỉ dựng từ train của khối; nạn nhân là tài khoản User có ≥ 7 ngày hoạt động trong train, mỗi tài khoản tối đa một lần; bỏ các (tài khoản, ngày) vốn đã bị luật cảnh báo trên log gốc.

Kịch bản	Hành vi được tiêm	Đề cương 5.2
`brute_force`	8–25 lần 4625 từ một nguồn lạ trong 5–30 phút; bị khoá sau L = 5 lần sai	Có

Kịch bản	Hành vi được tiêm	Đề cương 5.2
`password_spraying`	Một nguồn lạ thử 1–3 lần sai trên 5–13 tài khoản trong một cửa sổ 30–90 phút	Có
`off_hours`	Dời toàn bộ một ngày hoạt động điển hình sang 0–7 giờ	Có
`new_workstation_burst`	Đăng nhập thành công từ 4–10 máy chưa từng dùng trong 0,5–2 giờ	Có
`dormant_wakeup`	Tài khoản im lặng lâu hơn khoảng nghỉ dài nhất của chính nó bỗng có một ngày hoạt động điển hình	Có
`logon_type_switch`	Cả ngày đăng nhập chuyển sang loại logon chưa từng dùng, ưu tiên 2 → 3/5	Một phần (log chỉ có khoảng 35 tài khoản chủ yếu dùng type 2)

Lượng tiêm: mỗi run tiêm đúng 1% số dòng User của khối chấm (đề cương: 0,5–1%): dev 553 nạn nhân/run, test 1.543 nạn nhân/run (257–258 mỗi kịch bản). Mỗi khối có 5 run với 5 seed tiêm khác nhau.

Bộ tiêm đã được đối chiếu với đề cương và sửa 4 chỗ (2 lỗi mã, 2 lệch thiết kế) trước khi chạy lưới chính thức; chi tiết ở `reports/week4/tom_tat_tuan4.md` mục 2.3.

3.4.3. Chỉ số

Chỉ số	Định nghĩa	Vai trò
Recall top-100/ngày	Mỗi ngày lấy 100 dòng điểm cao nhất; tỷ lệ nạn nhân lọt vào, gộp qua các ngày	Chỉ số chính: khớp năng lực xem khoảng 100 cảnh báo/ngày của SOC (khoảng 1,2% số dòng User mỗi ngày)
PR-AUC	Diện tích dưới đường precision–recall	Chỉ số chính của đề cương; đo chất lượng xếp hạng toàn danh sách
ROC-AUC	Khả năng phân tách tổng thể	Chỉ số phụ; dùng khi so theo kịch bản
P@10/50/100	Tỷ lệ nạn nhân trong K dòng điểm cao nhất của cả khối	Trải nghiệm analyst
Recall tại ngân sách 5%	Recall khi cảnh báo 5% dòng điểm cao nhất	Đề cương 5.4
Tỷ lệ cảnh báo	Tỷ lệ dòng vượt ngưỡng train	Gánh nặng vận hành
Thời gian fit / chấm	Đo trên cùng máy	Khả năng mở rộng

Recall top-100/ngày được chọn làm chỉ số chính vì ROC-AUC quá lạc quan khi dương chỉ chiếm 1% (ví dụ IF có ROC-AUC cao hơn OCSVM nhưng chỉ bắt khoảng 70% số nạn nhân của OCSVM trong 100 cảnh báo/ngày), còn PR-AUC cộng cả những mức recall analyst không bao giờ đạt tới. Cài đặt: `src/evaluation/metrics.py`, có unit test.

3.4.4. Seed, chọn cấu hình và nhật ký

- **Một "seed" = một cặp (run tiêm, `random_state` mô hình):** 5 cặp với model seed 42, 7, 2024, 1, 2. Độ lệch chuẩn vì vậy gồm cả biến động của dữ liệu tiêm lẫn của mô hình.
- Quy tắc chọn cấu hình (ghi trong manifest trước khi chạy): PR-AUC trung bình cao nhất trên dev.
- Dòng train được sắp cố định trước khi fit, vì IF (lấy mẫu con) và OCSVM (SGD) phụ thuộc thứ tự dòng.
- Nhật ký chung `experiments/logs/experiment_log.csv`: mọi lần fit ghi thời điểm, commit, cấu hình, run, seed, kết quả (đề cương 5.6). Mỗi lưới có thêm `grid_manifest.json` với commit, phiên bản thư viện và sha256 của ma trận đầu vào.

4. Kết quả

4.1. Lưới cấu hình trên dev (22 đặc trưng)

Bảng 4.1: 3 mô hình × 13 cấu hình, TB ± std qua 5 run dev (cấu hình được chọn in đậm)

Mô hình	Cấu hình	Recall top-100/ngày	PR-AUC
IF	mặc định (100 cây, max_samples auto)	0,238 ± 0,011	0,093 ± 0,010
IF	300 cây, max_samples 1024	0,264 ± 0,012	0,128 ± 0,016
IF	max_features 0,5	0,227 ± 0,036	0,093 ± 0,016
LOF	k = 20, RobustScaler	0,192 ± 0,025	0,078 ± 0,025
LOF	k = 20, StandardScaler	0,060 ± 0,010	0,014 ± 0,001
LOF	k = 20, QuantileTransformer	0,082 ± 0,015	0,027 ± 0,002
LOF	k = 100, StandardScaler	0,084 ± 0,016	0,018 ± 0,002
OCSVM	RobustScaler	0,094 ± 0,026	0,033 ± 0,010
OCSVM	StandardScaler, γ = scale, 300 thành phần	0,412 ± 0,034	0,239 ± 0,026
OCSVM	QuantileTransformer	0,174 ± 0,016	0,073 ± 0,006
OCSVM	StandardScaler, 1.000 thành phần (`nc1000`)	0,383 ± 0,067	0,227 ± 0,049
OCSVM	StandardScaler, γ = 0,005	0,395 ± 0,015	0,215 ± 0,009
OCSVM	StandardScaler, γ = 0,1 (`g01`)	0,407 ± 0,033	0,248 ± 0,028

Ba cấu hình OCSVM StandardScaler hàng đầu chênh nhau dưới 1 std; theo quy tắc chọn đã ghi (PR-AUC), `g01` được chọn. Mỗi run dev có khoảng 54.960 dòng chấm và 553 nạn nhân.

Nguồn: `experiments/grid/dev_22f/` · Cấu hình: `configs/benchmark_grid_dev_22f.yaml`

4.2. Benchmark cuối trên test

Bảng 4.2: TB ± std qua 5 run test, 22 đặc trưng, tỷ lệ dương 1,01% (mỗi run khoảng 153.570 dòng chấm, 1.543 nạn nhân)

Mô hình	PR-AUC	ROC-AUC	P@10	P@50	P@100	Recall top-100/ngày	Recall top 5%	Tỷ lệ cảnh báo	Fit (s)	Chấm (s)
OCSVM (`g01`)	0,175 ± 0,048	0,892 ± 0,032	0,46 ± 0,18	0,38 ± 0,10	0,29 ± 0,10	0,336 ± 0,070	0,606 ± 0,054	0,069 ± 0,005	5 ± 0	0,9 ± 0,1
IF	0,111 ± 0,011	0,921 ± 0,005	0,24 ± 0,17	0,19 ± 0,03	0,22 ± 0,03	0,242 ± 0,016	0,468 ± 0,028	0,067 ± 0,001	12 ± 1	2,2 ± 0,1
LOF	0,071 ± 0,013	0,717 ± 0,007	0,28 ± 0,36	0,11 ± 0,14	0,11 ± 0,10	0,175 ± 0,006	0,360 ± 0,017	0,065 ± 0,001	8 ± 0	2,6 ± 0,1
Z-score	0,032 ± 0,003	0,743 ± 0,003	0,14 ± 0,09	0,25 ± 0,10	0,23 ± 0,04	0,075 ± 0,011	0,154 ± 0,010	0,072 ± 0,001	2 ± 0	0,2 ± 0,0
Luật 6 điều kiện	0,015 ± 0,001	0,536 ± 0,004	0,00 ± 0,00	0,02 ± 0,03	0,04 ± 0,03	0,073 ± 0,012	0,124 ± 0,011	0,361 ± 0,000	1 ± 0	0,1 ± 0,0
Luật thất bại ≥ 5	0,025 ± 0,000	0,623 ± 0,005	0,00 ± 0,00	0,00 ± 0,00	0,01 ± 0,00	0,098 ± 0,010	0,198 ± 0,002	0,050 ± 0,000	1 ± 0	0,1 ± 0,0
Ngẫu nhiên	0,010 ± 0,000	0,503 ± 0,013	0,02 ± 0,04	0,01 ± 0,02	0,02 ± 0,01	0,014 ± 0,003	0,052 ± 0,007	0,050 ± 0,001	2 ± 0	0,3 ± 0,0
OCSVM `nc1000` (đối chiếu)	*0,189 ± 0,013*	*0,908 ± 0,005*	*0,30 ± 0,19*	*0,29 ± 0,16*	*0,25 ± 0,15*	*0,373 ± 0,022*	*0,639 ± 0,022*	*0,074 ± 0,002*	*47 ± 2*	*3,7 ± 0,1*

Ghi chú: P@K tính trên cả khối 18 ngày; tỷ lệ cảnh báo ở contamination 5%; luật 6 điều kiện không có ngưỡng điều chỉnh được nên cờ 36% số dòng; thời gian đo trên 315 nghìn dòng train và 154 nghìn dòng test, CPU đa luồng.

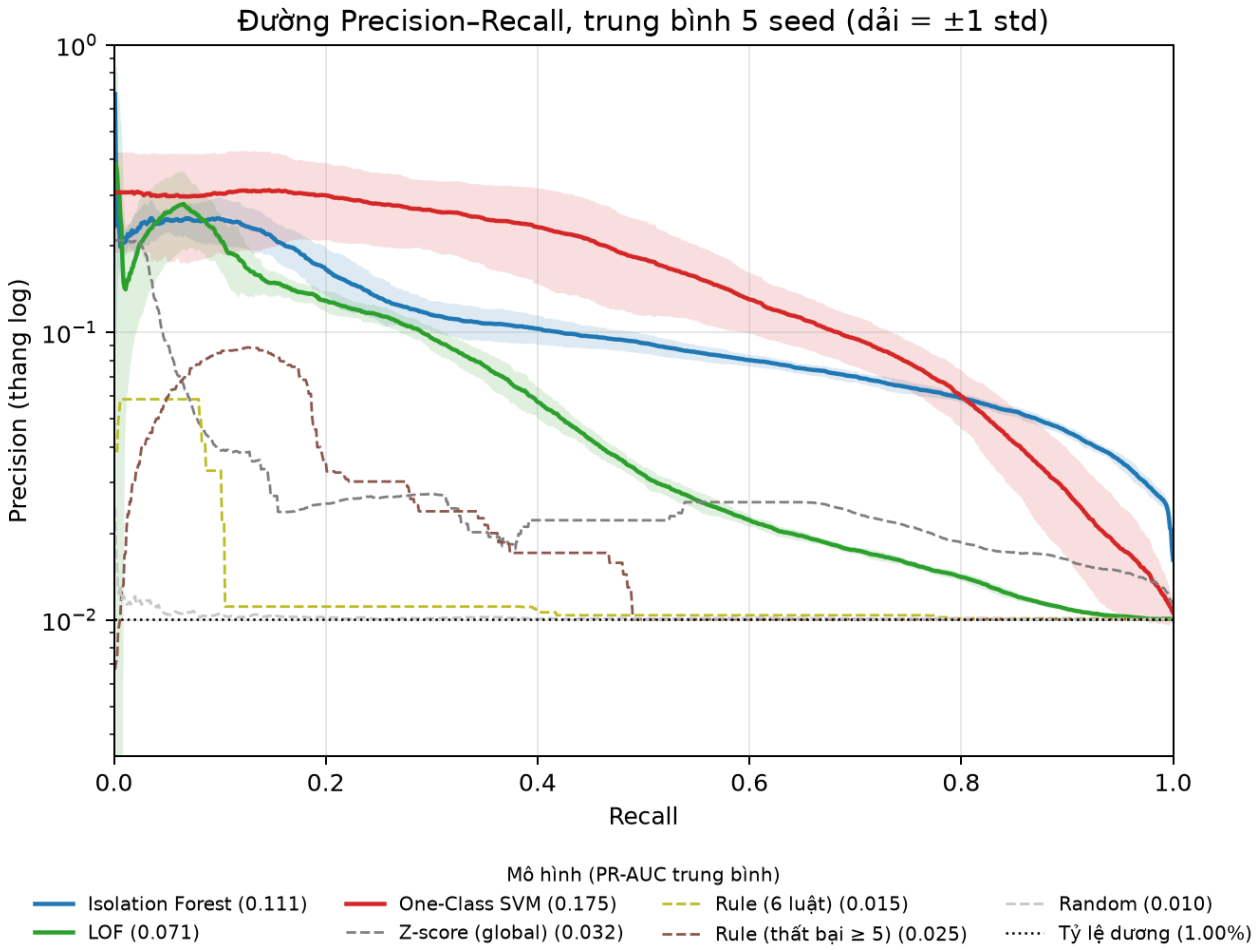
Trả lời Q1 và Q2:

1. OCSVM tốt nhất theo cả chỉ số chính lẫn PR-AUC. Với 100 cảnh báo/ngày, OCSVM bắt khoảng một phần ba số nạn nhân, và khoảng 29% cảnh báo là đúng (precision top-100/ngày 0,29).
2. **Cả ba mô hình đều vượt hai mốc của đề cương.** So với luật thất bại ≥ 5: OCSVM gấp 3,4 lần về recall top-100/ngày và 7 lần về PR-AUC; IF gấp 2,5 và 4,4 lần; LOF gấp 1,8 và 2,8 lần. So với ngẫu nhiên: PR-AUC gấp 7–17 lần.
3. **ROC-AUC không phân biệt được mô hình tốt:** IF có ROC-AUC cao nhất (0,921) nhưng recall top-100/ngày chỉ bằng khoảng 70% OCSVM. Phần danh sách mà ROC-AUC "thưởng" là phần không ai đọc tới.

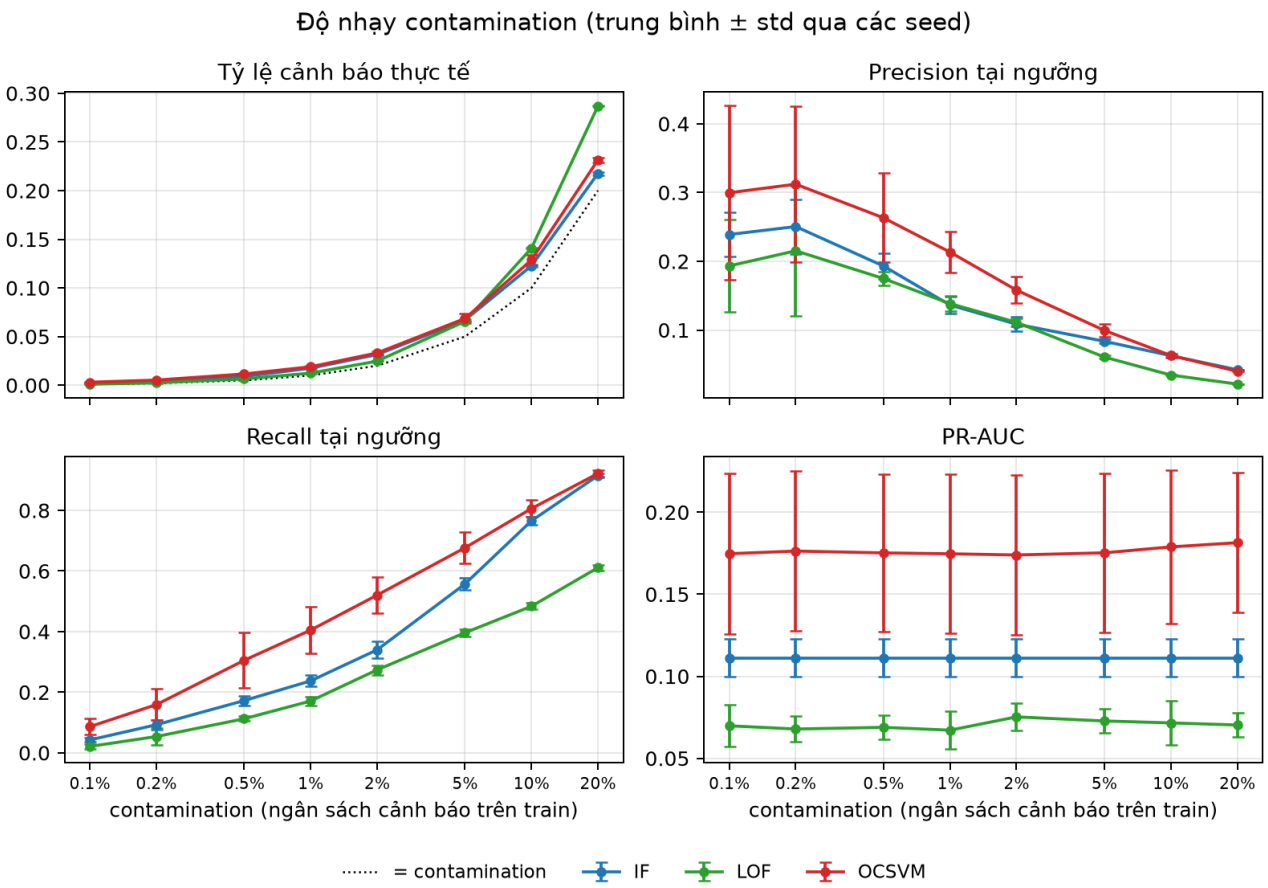
4. **Mô hình đa biến có giá trị gia tăng thật:** z-score (cùng đặc trưng, không mô hình hoá tương quan) chỉ đạt 0,075 recall.
5. Luật thất bại xếp hạng kém (P@10 = 0): những dòng có nhiều lần thất bại nhất là tài khoản thật vốn hay gõ sai, không phải nạn nhân. Luật đếm thất bại đơn thuần vì vậy sinh nhiều báo động giả.

Nguồn: `experiments/grid/test_22f/` (`grid_summary.csv`, `grid_runs.csv`) · OCSVM `nc1000`: `experiments/grid/test_22f_nc1000/`

4.3. Đường PR và độ nhạy contamination



Hình 4.1. Đường precision–recall trung bình qua 5 seed (vertical averaging, không chọn seed đẹp nhất). OCSVM giữ precision khoảng 0,3 tới recall khoảng 0,3 rồi giảm dần; z-score có precision cao ở vài cảnh báo đầu rồi rơi nhanh.



Hình 4.2 và bảng 4.3: Độ nhạy contamination (đề cương 5.6: 0,1–5%, thêm 10% và 20%)

c	OCSVM P / R	IF P / R	LOF P / R	Tỷ lệ cảnh báo thực tế (OCSVM)	Cảnh báo/ngày (OCSVM, khoảng)
0,1%	0,30 / 0,09	0,24 / 0,04	0,19 / 0,02	0,3%	25
0,2%	0,31 / 0,16	0,25 / 0,09	0,22 / 0,05	0,5%	40
0,5%	0,26 / 0,31	0,19 / 0,17	0,18 / 0,11	1,2%	100
1%	0,21 / 0,41	0,14 / 0,24	0,14 / 0,17	1,9%	160
2%	0,16 / 0,52	0,11 / 0,34	0,11 / 0,27	3,3%	280
5%	0,10 / 0,68	0,08 / 0,56	0,06 / 0,40	6,9%	590

- **Contamination chỉ dời điểm vận hành, không đổi chất lượng xếp hạng:** PR-AUC OCSVM chỉ dao động 0,174–0,181 dù `nu` đổi theo contamination; IF và LOF chỉ đổi ngưỡng.
- **Chọn contamination là chọn ngân sách analyst.** Ở c = 0,5%, OCSVM bật khoảng 100 cảnh báo/ngày (khoảng 8.500 dòng User/ngày), cứ khoảng 4 cảnh báo có 1 tấn công, bắt khoảng 31% nạn nhân.
- Tỷ lệ cảnh báo thực tế cao hơn contamination 1,4–2,5 lần vì khối chấm có thêm 1% dương và hành vi trôi so với train. Ngưỡng đặt theo phân vị train không giữ đúng ngân sách khi dữ liệu trôi; cần theo dõi khi triển khai.

4.4. Theo loại tấn công

Bảng 4.4: ROC-AUC theo kịch bản, test, 22 đặc trưng, TB 5 run

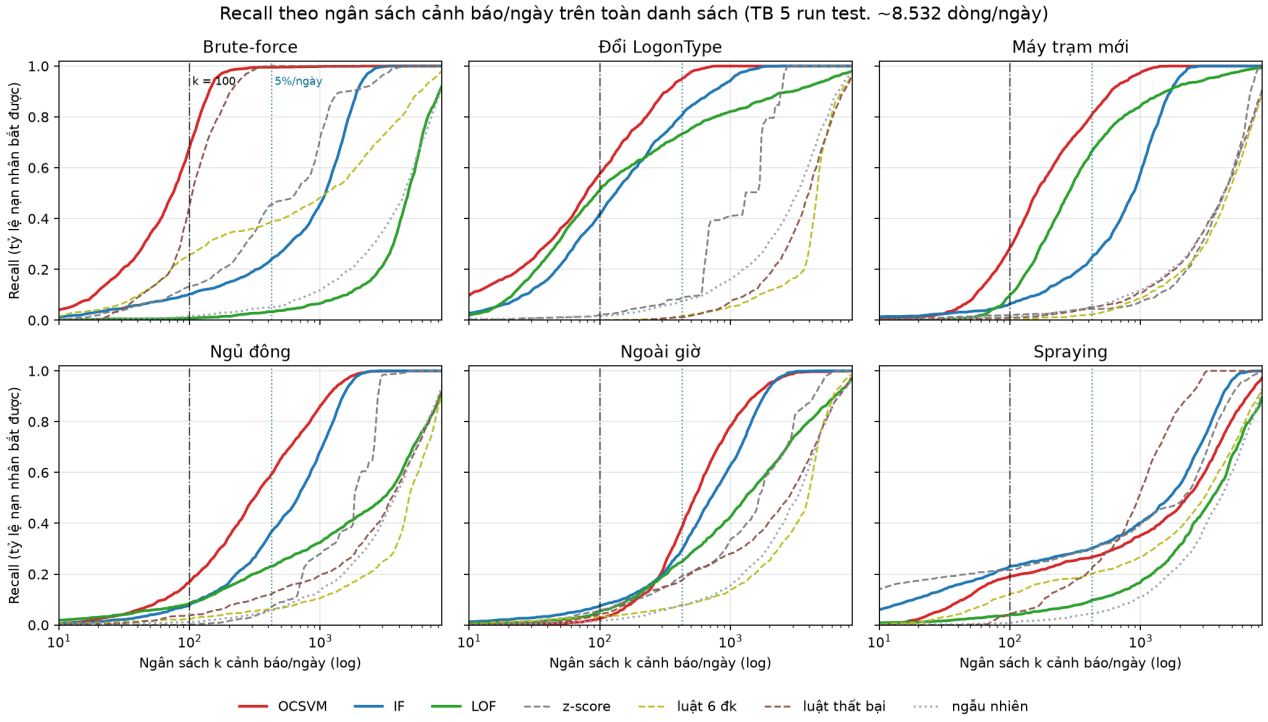
Kịch bản	OCSVM	IF	LOF	Z-score	Luật thất bại	Luật 6 đk	Ngẫu nhiên
brute_force	0,992	0,945	0,581	0,915	0,988	0,751	0,500
logon_type_switch	0,973	0,967	0,909	0,791	0,359	0,406	0,501

Kịch bản	OCSVM	IF	LOF	Z-score	Luật thất bại	Luật 6 đk	Ngẫu nhiên
new_ workstation_ burst	0,973	0,959	0,936	0,521	0,495	0,459	0,491
dormant_wakeup	0,907	0,942	0,554	0,785	0,513	0,418	0,513
off_hours	0,801	0,872	0,739	0,687	0,510	0,571	0,508
password_ spraying	0,709	0,842	0,586	0,759	0,875	0,613	0,503

ROC-AUC theo kịch bản được tính với cùng tập dòng âm. Để thấy mức "lọt vào ngân sách", bảng 4.5 dùng recall top-100/ngày; bảng này đo với 41 đặc trưng và OCSVM `nc1000` (thí nghiệm phân tích theo kịch bản tuần 5), nhưng thứ hạng kịch bản không đổi với bộ 22.

Bảng 4.5: Recall top-100/ngày theo kịch bản, test, 41 đặc trưng, TB 5 run

Kịch bản	OCSVM	IF	LOF	Z-score	Luật thất bại	Hạng trung vị của nạn nhân (OCSVM)
brute_force	0,68	0,10	0,01	0,13	0,45	top 0,8%
logon_type_ switch	0,58	0,42	0,51	0,02	0,00	top 1,2%
new_ workstation_ burst	0,29	0,07	0,10	0,02	0,01	top 1,8%
password_ spraying	0,19	0,23	0,04	0,22	0,05	top 26%
dormant_ wakeup	0,17	0,08	0,08	0,00	0,04	top 4,0%
off_hours	0,03	0,08	0,05	0,06	0,04	top 7,7%
Tất cả	0,32	0,16	0,13	0,08	0,10	



Hình 4.3. Recall theo ngân sách k cảnh báo/ngày, mỗi ô một kịch bản (41 đặc trưng). Đường càng lên sớm càng tốt.

Trả lời Q3:

- **Bắt tốt:** brute_force (OCSVM gần 0,7 ở 100 cảnh báo/ngày, gần 1,0 ở 5%), logon_type_switch (cả ba mô hình), new_workstation_burst (chủ yếu OCSVM).

- **Bắt yếu:** dormant_wakeup; nạn nhân bị bỏ sót lại có nhiều sự kiện hơn nạn nhân bị bắt (trung vị 150 so với 85), vì một ngày bận "phát lại" trông giống tài khoản bận bình thường.
- **Điểm mù chung:** off_hours và password_spraying. Cả ba kịch bản yếu được phân tích ở mục 5.5.
- **Không có mô hình nào thắng ở mọi kịch bản:** luật thất bại tốt nhất ở spraying về ROC-AUC; IF tốt hơn OCSVM ở dormant_wakeup và off_hours về ROC-AUC. Điều này ủng hộ việc kết hợp mô hình và luật (mục 8).

Nguồn: `experiments/grid/test_22f/grid_scenarios_summary.csv` · `experiments/analysis/scenario/` · `reports/week5/phan_tich_theo_kich_ban.md`

4.5. Chi phí tính toán

Bước	Thời gian	Ghi chú
Làm sạch + đặc trưng 60 ngày	vài giờ	Bước ghép lịch sử 7 ngày chiếm phần lớn; 14 ngày tốn thêm khoảng 200 s và gần gấp đôi RAM
Fit OCSVM `g01` / `nc1000`	5 s / 47 s	315 nghìn dòng train; `nc1000` dùng ma trận 315k × 1000 (> 2 GB, biến đổi theo khối)
Fit IF / LOF	12 s / 8 s	LOF HNSW đa luồng; LOF chính xác không khả thi ở quy mô này
Chấm 154 nghìn dòng	1–3 s mỗi mô hình	Đủ nhanh cho chấm theo lô hằng ngày
Lưới test (3 mô hình + 4 baseline × 5 seed + quét contamination)	khoảng 1 giờ	Phần lớn là 120 lần fit của quét contamination

5. Phân tích

5.1. Vì sao OCSVM vượt LOF

Nhiều bài so sánh xếp OCSVM ở nhóm kém. Kết quả ngược lại ở đây có ba nguyên nhân:

1. **Loại bất thường quyết định thuật toán thắng.** Các khảo sát lớn (ví dụ ADBench, NeurIPS 2022) cho thấy phương pháp toàn cục thắng với bất thường toàn cục, còn LOF mạnh với bất thường cục bộ. Năm trên sáu kịch bản ở đây là bất thường toàn cục: bị khoá tài khoản, nhiều máy nguồn mới, cả ngày đổi loại logon.
2. Bằng chứng trực tiếp: LOF gần như mù với brute-force (ROC-AUC 0,58, recall top-100/ngày 0,01) trong khi OCSVM đạt 0,99. Train có sẵn khoảng 600 dòng User thật giống brute-force (bị khoá, ≥ 8 lần thất bại). Nạn nhân tiêm có láng giềng gần nhất chính là các dòng này, mật độ tương đương nên LOF ≈ 1, tức "bình thường". OCSVM đo khoảng cách tới khối dữ liệu chính; 600 trên 315.000 dòng là vùng thưa nên bị coi là bất thường.
3. Tiền xử lý quyết định (mục 5.2).

5.2. Scaler: lựa chọn "an toàn" theo sách giáo khoa có thể sai

`RobustScaler` chia mỗi đặc trưng cho IQR của train. Trên dữ liệu UEBA, nhiều đặc trưng là tỷ lệ phần lớn bằng 0: đặc trưng có IQR rất nhỏ bị phóng đại (`failure_ratio` lên khoảng 1.400 đơn vị), còn đặc trưng có IQR = 0 giữ nguyên đơn vị gốc, trong đó có chính các đặc trưng tách nạn nhân tốt nhất. Mô hình dựa trên khoảng cách chỉ "thấy" vài đặc trưng bị phóng đại.

OCSVM, dev, 22 đặc trưng	Recall top-100/ngày	PR-AUC
RobustScaler	0,094	0,033
QuantileTransformer	0,174	0,073
StandardScaler	0,412	0,239

LOF thì ngược lại: RobustScaler tốt nhất (0,078 so với 0,014 PR-AUC), vì nó bắt mạnh vài kịch bản có đặc trưng bị phóng đại. Isolation Forest không bị ảnh hưởng vì không phụ thuộc thang đo. Bài học: cần kiểm tra thang đo sau tiền xử lý trước khi kết luận một mô hình kém.

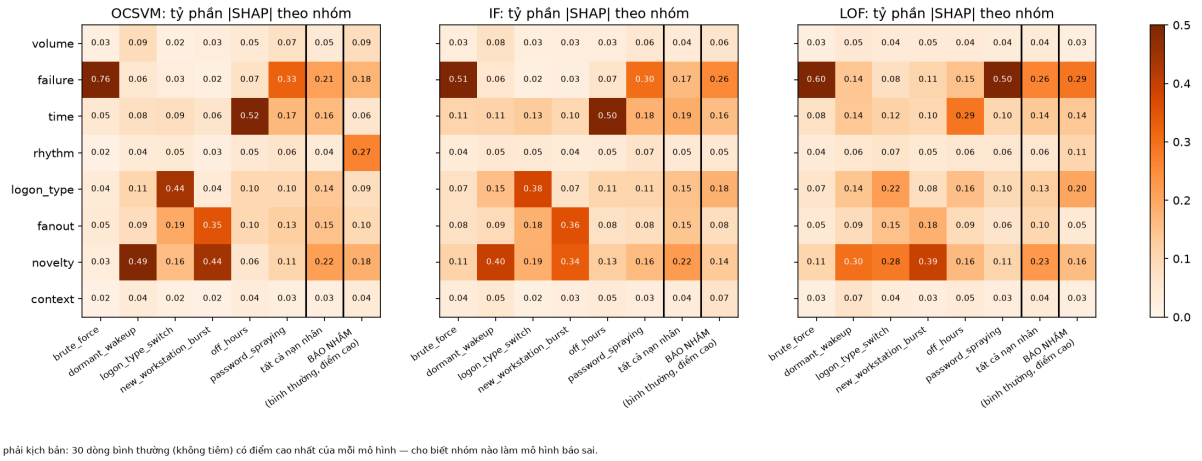
5.3. Chọn đặc trưng: từ 41 xuống 22

5.3.1. SHAP: mô hình dùng đúng tín hiệu

KernelSHAP trên một run dev, 180 nạn nhân (30 mỗi kịch bản) và 30 báo nhầm điểm cao nhất của mỗi mô hình. Mỗi dòng được chuẩn hoá thành tỷ phần |SHAP| để so giữa ba mô hình có thang điểm khác nhau.

Kịch bản	Nhóm đặc trưng chính (tỷ phần OCSVM / IF / LOF)
brute_force	failure 0,76 / 0,51 / 0,60
off_hours	time 0,52 / 0,50 / 0,29
logon_type_switch	logon_type 0,44 / 0,38 / 0,22
password_spraying	failure 0,33 / 0,30 / 0,50, sau đó là time
new_workstation_burst	novelty 0,44 / 0,34 / 0,39 và fanout 0,35 / 0,36 / 0,18
dormant_wakeup	novelty 0,49 / 0,40 / 0,30 (chủ yếu `days_since_last_activity`)
Báo nhầm (dòng bình thường điểm cao nhất)	OCSVM: rhythm 0,27; IF, LOF: failure

Mỗi kịch bản được giải thích bằng đúng nhóm đặc trưng thiết kế cho nó, nhất quán ở cả ba mô hình. Nhóm rhythm (nhịp giữa các sự kiện) chỉ chiếm khoảng nửa mức chia đều ở nạn nhân, nhưng chiếm 0,27 (gấp gần 3 lần mức chia đều) ở báo nhầm của OCSVM, gần như toàn bộ do `delta_t_cv`. LIME được chạy để đối chiếu nhưng khớp kém ở từng dòng (với LOF chỉ giải thích được 6% điểm), nên SHAP là căn cứ chính.



Hình 5.1. Tỷ phần |SHAP| theo nhóm (hàng) và kịch bản (cột), mỗi bảng một mô hình. Ô đậm gần như nằm trên một "đường chéo": mỗi kịch bản có đúng một nhóm nổi bật.

5.3.2. Ablation theo nhóm đặc trưng (đề cương 5.6)

Bỏ lần lượt từng nhóm, đo hiệu ghép cặp so với đủ 41 đặc trưng trên cùng run và seed (5 run dev). Đối chứng: chỉ xáo thứ tự dòng train đã làm PR-AUC OCSVM lệch −0,020 ± 0,019 (do SGD), nên với OCSVM một thay đổi phải vượt mức này.

Bỏ nhóm (còn lại)	ΔPR-AUC OCSVM	ΔPR-AUC IF	ΔPR-AUC LOF	Thay đổi rõ nhất theo kịch bản
failure (35)	−0,056 ± 0,018	−0,007	+0,002	OCSVM brute_force −0,57 recall
novelty (36)	−0,039 ± 0,016	−0,018	−0,028	OCSVM burst −0,32; LOF logon_type_switch −0,50
fanout (35)	−0,014 ± 0,003	−0,012	+0,002	OCSVM burst −0,14
logon_type (35)	−0,011 ± 0,005	+0,004	−0,012	logon_type_switch −0,14 đến −0,28
time (33)	−0,002 ± 0,003	+0,012	−0,012	off_hours gần như không đổi

Bỏ nhóm (còn lại)	ΔPR-AUC OCSVM	ΔPR-AUC IF	ΔPR-AUC LOF	Thay đổi rõ nhất theo kịch bản
volume + context (35)	+0,014 ± 0,003	+0,038	+0,003	không kịch bản nào tụt rõ
rhythm (37)	+0,050 ± 0,013	+0,019	+0,029	không kịch bản nào tụt; brute_force +0,13 (OCSVM)
đối chứng xáo dòng (41)	*−0,020 ± 0,019*	*0,000*	*−0,005*	

- failure và novelty là xương sống; bỏ chúng làm mất đúng kịch bản tương ứng.
- rhythm, volume, context có hại hoặc vô ích: bỏ đi làm cả ba mô hình tốt hơn.
- Bỏ nhóm time không làm off_hours tệ đi: các đặc trưng thời gian hiện có không giúp bắt kịch bản này (mục 5.5).

5.3.3. Chọn số đặc trưng bỏ (K)

Bộ 30 đặc trưng dùng trong tuần 5 được tạo bằng cách bỏ nhóm rhythm và 10 đặc trưng SHAP thấp nhất. Con số 10 là một số tròn được chọn, không có quy tắc nào đứng sau: khi xếp 41 đặc trưng theo mức đóng góp SHAP, các giá trị giảm đều và không có chỗ gãy. Trên run dev dùng để chọn bộ 30, hạng 10 (`same_second_share`) là 0,0163 và hạng 11 (`custom_proc_share`) là 0,0165, chỉ chênh 0,0002; tính trung bình 3 run thì hạng 10 là 0,0164, hạng 11 là 0,0171. Kết quả tốt của bộ 30 chỉ cho thấy bỏ các đặc trưng đó không gây hại, chứ không chứng minh 10 là con số đúng. Vì vậy số đặc trưng cần bỏ được chọn lại bằng đường cong K trên dev, với quy tắc chọn đặt ra trước khi xem kết quả.

Xếp 41 đặc trưng theo tỷ phần |SHAP| cao nhất qua 3 mô hình × 3 run dev; cấu hình `drop_rhythm_kK` bỏ rhythm và K đặc trưng thấp nhất. K = 18 là mức cắt tự nhiên: đúng 18 đặc trưng có tỷ phần dưới mức chia đều 1/41 ở mọi mô hình, mọi run.

Còn lại	OCSVM	IF	LOF
41 (đủ)	0,317 ± 0,058	0,139 ± 0,011	0,165 ± 0,017
37 (bỏ rhythm, K = 0)	0,368 ± 0,057	0,195 ± 0,023	0,197 ± 0,014
33 (K = 5)	0,377 ± 0,059	0,217 ± 0,014	0,197 ± 0,018
30 (rhythm + 10 SHAP thấp, bộ của tuần 5)	0,380 ± 0,059	0,228 ± 0,017	0,207 ± 0,014
29 (K = 10)	0,380 ± 0,061	0,235 ± 0,022	0,184 ± 0,015
25 (K = 15)	0,385 ± 0,059	0,246 ± 0,019	0,181 ± 0,015
22 (K = 18, chốt)	0,383 ± 0,067	0,264 ± 0,012	0,170 ± 0,006
21 (K = 20)	0,382 ± 0,064	0,258 ± 0,021	0,167 ± 0,016

Recall top-100/ngày, TB ± std qua 5 run dev, cấu hình mô hình của 41 đặc trưng. Bộ 30 dùng xếp hạng SHAP của 1 run, còn đường cong K xếp theo tỷ phần cao nhất qua 3 mô hình × 3 run, nên K = 10 cho 29 đặc trưng và không trùng với bộ 30 (bộ 30 giữ `custom_proc_share`, `delta_mean_distinct_pair_7d`, `new_host_count_7d` nhưng bỏ `peer_z_share_night`, `volume_robust_z_7d`). Nguồn: `experiments/ablation/kcurve/summary.csv`.

- OCSVM phẳng từ 33 đến 22 đặc trưng; IF tăng đều tới 22 rồi dừng; LOF tốt nhất ở 30–33 rồi giảm.
- **Không có K chung tốt nhất cho cả ba mô hình.** K = 18 được chốt vì là mức cắt có căn cứ, OCSVM không đổi, IF tăng rõ, và K = 20 không tốt hơn ở mô hình nào. Đánh đổi là LOF kém trên dev (−0,037 ± 0,009).
- Kiểm tra trên test (bảng 5.1 của báo cáo tuần 5): so với bộ 30, K = 18 cho OCSVM −0,003 ± 0,005, IF +0,034 ± 0,013, LOF +0,028 ± 0,005 recall. LOF đảo chiều giữa dev và test, nên không dùng LOF để chọn K.
- **Thiên lệch chọn:** K = 18 được chốt sau khi đã xem kết quả test của 4 cấu hình K. Với OCSVM và IF, test chỉ xác nhận dev; với LOF việc chọn có tính đến test. Đây là ngoại lệ duy nhất với nguyên tắc "test không tham gia chọn".

Kết quả so với 41 đặc trưng ban đầu (test): recall top-100/ngày IF 0,16 → 0,24, LOF 0,13 → 0,18, OCSVM 0,32 → 0,34 (`g01`; `nc1000` 0,37). Bớt chiều yếu giúp IF nhiều nhất vì IF chọn đặc trưng

ngẫu nhiên để tách, mỗi chiều yếu làm loãng cây.

Nguồn: `reports/week5/shap_lime.md` · `ablation_nhom_dac_trung.md` · `chon_so_dac_trung_K.md` · `kiem_tra_test_K_va_context.md`

5.4. Cửa sổ lịch sử 7 / 14 / 21 ngày

Kéo dài cửa sổ của các đặc trưng lịch sử không cải thiện kết quả: recall top-100/ngày OCSVM 0,317 / 0,318 / 0,294; LOF 0,121 / 0,034 / 0,003 (sụp ở cửa sổ dài vì nhiều dòng đầu train thiếu lịch sử bị điền median, tạo cụm dày giả). Cửa sổ dài chỉ giúp spraying (ROC-AUC 0,69 → 0,77) nhưng làm hại dormant_wakeup và tốn khoảng 3 lần thời gian. Giữ 7 ngày. Chi tiết: `reports/week5/bao_cao_tuan5.md` mục 1.

5.5. Ba kịch bản bị bắt kém: off_hours, password_spraying, dormant_wakeup

Các con số recall trong mục này lấy từ bảng 4.5 (41 đặc trưng).

off_hours (recall top-100/ngày $\leq$ 0,08 ở mọi mô hình):

- Nạn nhân bị bỏ sót có trung vị 107 sự kiện, nạn nhân bị bắt chỉ 9,5. Một ngày bận bị dời sang đêm vẫn trông như một tài khoản bận; trong không gian khoảng cách, vài chiều về ban đêm bị các chiều khối lượng lấn át.
- SHAP xác nhận nhóm time giải thích phần lớn điểm của nạn nhân (0,52), nhưng điểm tuyệt đối không đủ cao để lọt top.
- **Khung giờ đêm quá rộng.** Ngoài giờ là 18h–7h, tức 14/24 giờ, và chứa cả 7h, lúc lưu lượng ngày thường đã bằng 90% giờ cao điểm (mục 2.5). Một ngày bị dời vào khung này vì vậy không khác nhiều so với một ngày bình thường.
- **Nhóm đặc trưng thời gian hiện không tạo khác biệt:** bỏ cả 8 đặc trưng thời gian thì recall off_hours gần như không đổi ở cả 3 mô hình ($-$0,02 đến 0,00).
- **Không phải do lệch múi giờ:** nhịp lưu lượng theo giờ khớp với giờ địa phương (mục 2.5).
- Hướng sửa: thu hẹp khung giờ đêm, và dùng đặc trưng so giờ hoạt động với lịch sử giờ của chính tài khoản, hoặc một luật riêng.

password_spraying (recall $\leq$ 0,23):

- Mỗi nạn nhân chỉ nhận 1–3 lần thử. Ở mức (tài khoản, ngày) gần như không có tín hiệu; dấu hiệu thật là một máy nguồn làm nhiều tài khoản thất bại trong thời gian ngắn, nhưng mọi đặc trưng đều tính theo từng tài khoản.
- Luật thất bại có ROC-AUC tốt nhất (0,875) nhưng vẫn không đưa được nạn nhân vào top (recall 0,05).
- Hướng sửa: đặc trưng fan-out theo máy nguồn (engine đã có phép đo `fanout`), hoặc phân tích ở cấp máy nguồn thay vì cấp tài khoản. Không chỉnh tham số mô hình nào giải được vấn đề này.

dormant_wakeup (recall $\leq$ 0,17; ROC-AUC 0,91 với OCSVM và 0,94 với IF):

- Bộ tiêm phát lại một ngày bình thường của chính tài khoản sau một khoảng nghỉ dài. Chỉ có khoảng nghỉ là khác thường; khối lượng, máy và loại đăng nhập đều giống một ngày bình thường.
- Nạn nhân bị bỏ sót lại có nhiều sự kiện hơn nạn nhân bị bắt (trung vị 150 so với 85), vì một ngày bận trông giống một tài khoản bận bình thường.
- Tín hiệu rõ nhất chỉ còn `days_since_last_activity`. Sau khoảng nghỉ từ 7 ngày trở lên, các đặc trưng so với 7 ngày trước không có lịch sử để so (suy luận từ cách tính, chưa đo riêng).
- Hướng sửa: đặc trưng "khoảng nghỉ hôm nay so với khoảng nghỉ dài nhất trước đó của chính tài khoản".

Nguyên nhân chung. Cả ba kịch bản đều chạm vào giới hạn của cách đặt bài toán: mỗi dòng là một tài khoản trong một ngày. Spraying cần nhìn theo máy nguồn qua nhiều tài khoản; off_hours và dormant_wakeup cần so với lịch sử dài hơn của chính tài khoản. Chỉnh tham số mô hình không giải được các điểm mù này.

5.6. Độ ổn định

Qua seed. Std của recall top-100/ngày: IF 0,016, LOF 0,006, OCSVM `g01` 0,070. Std gồm cả biến động dữ liệu tiêm và mô hình. Riêng OCSVM còn nhạy với thứ tự dòng train (SGD), nên dòng được

sắp cố định trước khi fit.

Chọn cấu hình OCSVM trên dev không lặp lại trên test. Trên dev, `g01` thắng `nc1000` với mức chênh nhỏ hơn 1 std. Trên test:

OCSVM, test	PR-AUC từng run	TB ± std	Recall top-100/ngày
`g01` (300 thành phần Nystroem, $\gamma = 0{,}1$)	0,19 / 0,20 / 0,11 / 0,15 / 0,24	0,175 ± 0,048	0,336 ± 0,070
`nc1000` (1.000 thành phần, $\gamma =$ scale)	0,19 / 0,19 / 0,17 / 0,20 / 0,20	0,189 ± 0,013	0,373 ± 0,022

Chênh lệch trung bình nằm trong 1 std, nhưng `g01` dao động gấp khoảng 3–4 lần. Nhiều thành phần Nystroem hơn làm xấp xỉ nhân RBF ổn định hơn. Kết quả chính vẫn báo cáo `g01` (cấu hình chọn trên dev), vì đổi sang `nc1000` sau khi xem test là chọn mô hình bằng tập test. Đề cương ghi "một mô hình có phương sai lớn giữa các seed là mô hình không đáng tin để triển khai"; vì vậy khuyến nghị triển khai là `nc1000` (mục 8), và quy tắc chọn cấu hình về sau nên xét cả trung bình lẫn độ lệch chuẩn trên dev.

LOF không tất định. Chỉ mục HNSW dựng đa luồng (`n_jobs: -1`) đổi thứ tự chèn mỗi lần fit:

- Trung bình 5 run lặp lại được: hai lần chạy lưới test cho recall 0,176 và 0,175, PR-AUC 0,070 và 0,071.
- Nhưng từng lần fit lệch nhiều: PR-AUC của run seed 42 là 0,072 / 0,075 / 0,079 / 0,083 qua bốn lần fit (lệch tới khoảng 15%), và top 50 cảnh báo của hai lần fit trên log gốc chỉ trùng 6/50.
- Hệ quả: danh sách cảnh báo của LOF không tái lập được. Đặt `n_jobs: 1` cho kết quả tất định nhưng fit chậm hơn nhiều; nhóm giữ đa luồng và ghi nhận đây là hạn chế.

5.7. Mức lạc quan của kết quả

- **Do chọn cấu hình trên dev:** nhỏ. Dev nằm trong train; với cấu hình 41 đặc trưng, PR-AUC test bằng hoặc cao hơn dev ở cả ba mô hình. Với 22 đặc trưng, PR-AUC test thấp hơn dev (OCSVM 0,175 so với 0,248), một phần do dev và test khác nhau về độ dài train và số ngày chấm.
- **Do nhãn tổng hợp:** lớn và không đo được. Tấn công tiêm là bản sao sự kiện thật nhưng theo khuôn cố định; tấn công thật đa dạng và kín đáo hơn. Mọi con số trong báo cáo là cận trên.

6. Đánh giá định tính: review thủ công top 50

6.1. Thiết lập

Trên log gốc, không tiêm, mô hình fit ngày 1–42 và chấm ngày 43–60 (phân khúc User, seed 42). Lấy 50 cảnh báo điểm cao nhất của mỗi mô hình, hợp lại, xáo thứ tự và làm mù (phiếu chấm không có tên mô hình hay điểm; bảng khoá để riêng). Mỗi cảnh báo có một "thẻ" gồm đặc trưng lệch nhất so với train, ngữ cảnh tài khoản và tóm tắt log thô của ngày đó. Ba nhãn theo đề cương 5.5: a đáng ngờ, cần điều tra; b bất thường nhưng giải thích được; c nhiễu. Hướng dẫn chấm: `docs/huong_dan_review_top50.md`.

6.2. Trạng thái

Bộ	Mô hình	Số cảnh báo	Người chấm	Trạng thái
`review_top50_22f`	22 đặc trưng, OCSVM `g01`	148	2 thực tập sinh, độc lập	Chưa chấm

> Một phần Mục này chưa hoàn chỉnh. Đề cương yêu cầu hai thực tập sinh chấm độc lập rồi đo đồng thuận (Cohen's κ, chạy `python scripts/evaluation/review_agreement.py`). Khi có nhãn của hai người, mục này cần bổ sung bảng phân loại a/b/c theo mô hình, κ và nhận xét.

Nguồn: `experiments/analysis/review_top50_22f/`

7. Hạn chế đã biết

1. **Nhãn tổng hợp cho cận trên lạc quan.** Tấn công thật đa dạng và kín đáo hơn khuôn tiêm; dòng nhãn 0 cũng chưa chắc lành tính. Không có nhãn tấn công thật để hiệu chỉnh.
2. **Giả định train "sạch" không hoàn toàn đúng.** Train có khoảng 600 dòng giống brute-force thật; chính chúng làm LOF thất bại.
3. **Chỉ đánh giá phân khúc User.** Tài khoản Machine không được tiêm; Admin, Service, System quá ít để học máy.
4. Ba kịch bản bị bắt kém: password_spraying, off_hours, dormant_wakeup (recall top-100/ngày $\leq$ 0,23 / 0,08 / 0,17, số của 41 đặc trưng). Nguyên nhân: (a) đặc trưng chỉ tính theo từng tài khoản, nên không thấy một máy nguồn thử nhiều tài khoản; (b) khung giờ đêm 18h–7h quá rộng, chứa cả giờ làm việc lúc 7h; (c) ngày "thức dậy" giống một ngày bình thường, chỉ khác khoảng nghỉ. Chi tiết và hướng sửa ở mục 5.5.
5. **Thuật toán xấp xỉ.** LOF dùng láng giềng xấp xỉ HNSW, OCSVM dùng nhân RBF xấp xỉ Nystroem + SGD, thay cho bản chính xác của scikit-learn. Kết luận về "LOF" và "OCSVM" là kết luận về các bản xấp xỉ này.
6. LOF không tất định ở mức từng lần fit (mục 5.6); danh sách cảnh báo LOF không tái lập được.
7. OCSVM `g01` kém ổn định trên test; quy tắc chọn chỉ dựa trên trung bình.
8. Thiên lệch chọn ở bước chọn K (mục 5.3.3): K = 18 được chốt sau khi xem test.
9. **Train dùng chung cho mọi run:** chỉ ngày chấm bị tiêm, nên độ lệch chuẩn không gồm biến động của train.
10. Ngưỡng theo phân vị train không giữ ngân sách khi hành vi trôi: tỷ lệ cảnh báo thực tế cao hơn contamination 1,4–2,5 lần.
11. Đổi LogonType chỉ có 5–8 nạn nhân/run theo đúng chiều 2 $\rightarrow$ 3/5 của đề cương.
12. Review thủ công của bộ 22 đặc trưng chưa có nhãn của hai người, nên báo cáo chưa có kết quả định tính trên log thật.
13. Tái lập trên máy sạch chưa được thực hiện (mục 9).

8. Khuyến nghị triển khai

8.1. Kiến trúc phân luồng theo loại tài khoản

Luồng	Đối tượng	Phương pháp
Học máy	Tài khoản User (khoảng 45% dòng)	OCSVM làm điểm chính, IF làm mô hình phụ
Luật dò/rải mật khẩu	Mọi tài khoản, theo máy nguồn	Đếm số tài khoản thất bại theo `Source` trong cửa sổ ngắn; luật số lần thất bại theo tài khoản
Luật và danh sách trắng	Admin, Service, System	Mỗi tài khoản dịch vụ chỉ được phép một tập (loại logon, nguồn, đích) cố định; vi phạm là cảnh báo mức cao
Theo dõi riêng (chưa đánh giá)	Machine	Cần đánh giá riêng trước khi đưa vào học máy

8.2. Cấu hình mô hình

1. OCSVM StandardScaler, 1.000 thành phần Nystroem (`nc1000`), 22 đặc trưng. Lý do: recall top-100/ngày 0,373 $\pm$ 0,022, ổn định nhất trong các cấu hình OCSVM tốt; `g01` nhanh hơn 9 lần nhưng dao động lớn (mục 5.6). Nếu ràng buộc thời gian fit quan trọng hơn, dùng `g01` và theo dõi chặt chỉ số hằng ngày.
2. IF 300 cây, max_samples 1024 làm mô hình phụ: tốt hơn OCSVM ở dormant_wakeup và off_hours về ROC-AUC.
3. Không dùng LOF ở cấu hình hiện tại: kém nhất trên nhãn tổng hợp và không tất định.
4. Kiểm tra thang đo sau tiền xử lý mỗi khi đổi bộ đặc trưng (mục 5.2).

8.3. Ngân sách cảnh báo và chi phí vận hành

Ngân sách	Contamination (khoảng)	Recall (OCSVM)	Cảnh báo đúng / cảnh báo	Thời gian analyst (giả định 5 phút/cảnh báo)
khoảng 40 cảnh báo/ngày	0,2%	0,16	khoảng 1/3	khoảng 3,3 giờ/ngày
khoảng 100 cảnh báo/ngày	0,5%	0,31	khoảng 1/4	khoảng 8 giờ/ngày (1 analyst)
khoảng 280 cảnh báo/ngày	2%	0,52	khoảng 1/6	khoảng 23 giờ/ngày (3 analyst)

Khuyến nghị khởi đầu ở khoảng 100 cảnh báo/ngày (một analyst toàn thời gian) và đặt ngân sách theo số cảnh báo/ngày (top-K mỗi ngày) thay vì theo contamination, vì ngưỡng phân vị train không giữ đúng ngân sách khi dữ liệu trôi. Thời gian 5 phút/cảnh báo là giả định để minh hoạ, chưa đo thực tế. Các con số recall là cận trên (nhãn tổng hợp).

8.4. Vận hành và theo dõi

1. Huấn luyện lại định kỳ (gợi ý hằng tuần) trên cửa sổ trượt; theo dõi tỷ lệ cảnh báo và phân bố điểm theo ngày để phát hiện trôi dữ liệu.
2. Giải thích từng cảnh báo bằng SHAP theo nhóm đặc trưng giúp analyst biết cảnh báo thuộc loại nào (thất bại, nguồn mới, loại logon, . . .).
3. **Ưu tiên cải tiến tiếp theo:** đặc trưng fan-out theo máy nguồn (spraying), đặc trưng giờ so với lịch sử cá nhân (off_hours), rồi đánh giá trên tấn công thật nếu có (ví dụ `redteam.txt` của LANL).

9. Tái lập và vận hành

9.1. Môi trường

Conda hoặc venv, cài theo README mục 2 (`pip install -r requirements.txt`, `pip install -e .`). Dữ liệu interim (khoảng 22 GB) tải từ Google Drive (README mục 6) vì không nằm trong Git. Toàn bộ tham số nằm trong `configs/`; không có đường dẫn tuyệt đối trong mã.

Phiên bản đã sinh ra bảng 4.2. `requirements.txt` chỉ ghi phiên bản tối thiểu (`>=`), nên cài mới hôm nay có thể nhận phiên bản khác. Để chạy lại đúng như báo cáo, cài đúng các phiên bản sau. Chúng được ghi tự động trong `experiments/grid/test_22f/grid_manifest.json` lúc chạy lưới:

Thư viện	Phiên bản
Python	3.14.6
numpy	2.5.3
pandas	3.0.5
polars	1.44.2
pyarrow	24.0.0
scipy	1.18.1
scikit-learn	1.9.1
joblib	1.6.0

Ví dụ: `pip install numpy==2.5.3 pandas==3.0.5 polars==1.44.2 pyarrow==24.0.0 scipy==1.18.1 scikit-learn==1.9.1 joblib==1.6.0`, rồi `pip install -r requirements.txt` cho các thư viện còn lại. Manifest chưa ghi phiên bản của `pyod`, `hnswlib`, `shap` và `lime` (mục 9.5).

Kiểm tra dữ liệu sau khi tải: `python scripts/validate_interim.py` phải báo 120 file hợp lệ, gồm 929.103.392 dòng 4624 và 13.823.040 dòng 4625.

9.2. Một lệnh

```
python scripts/reproduce.py        # đặc trưng, hồ sơ train, baseline, tiêm 5 run test, lưới 22 đặc
↪  trưng, đối chiếu số
```

Kết quả ghi vào `experiments/reproduce/test_22f/` kèm `reproduce_check.csv`, so từng chỉ số với `experiments/grid/test_22f/grid_summary.csv`; đạt khi sai lệch tương đối $\leq 1\%$ (LOF $\leq 5\%$, mục

5.6). Mọi bước ngẫu nhiên có seed cố định: seed tiêm trong `configs/injection.yaml`, model seed trong cấu hình lưới.

9.3. Từng bước

```
python -m pytest tests -q                                                    # 258 test
python main.py --stage features                                              # log -> ma trận đặc trưng
python main.py --stage inject --block test                                   # tiêm một run
python scripts/evaluation/run_grid.py --config configs/benchmark_grid_dev_22f.yaml    # bảng 4.1,
↪  khoảng 15 phút
python scripts/evaluation/run_grid.py --config configs/benchmark_grid_test_22f.yaml   # bảng 4.2-4.4,
↪  khoảng 1 giờ
python scripts/evaluation/explain_models.py                                  # SHAP/LIME
python scripts/evaluation/feature_ablation.py [--mode kcurve]                # ablation nhóm / chọn K
python scripts/evaluation/build_review_set.py --config configs/benchmark_grid_test_22f.yaml --out
↪  experiments/analysis/review_top50_22f
python scripts/evaluation/review_agreement.py                                # Cohen's kappa
python scripts/evaluation/train_demo_models.py                               # lưu 3 mô hình cho demo
```

9.4. Mô hình cho demo

`scripts/evaluation/train_demo_models.py` fit 3 mô hình của bảng 4.2 trên log gốc ngày 1–42 (seed 42), lưu pipeline (điền thiếu + scaler + mô hình) vào `experiments/models/User_22f/*.joblib`, rồi nạp lại và so PR-AUC với lưới (IF và OCSVM khớp tuyệt đối, LOF lệch do không tất định). Dùng: `AnomalyPipeline.load(path).score(df)`.

9.5. Trạng thái kiểm chứng

- `pytest`: 258 test pass trên máy phát triển; bản clone sạch chạy được test mà không cần dữ liệu ngoài Git (trừ 2 test cần ma trận).
- Chưa chạy `reproduce.py` trọn vẹn trên một máy sạch do người thứ ba thực hiện (tiêu chí 4.1 #1).
- Chưa có file khoá phiên bản (`pip freeze` của môi trường đã chạy lưới). Bảng phiên bản ở mục 9.1 thiếu `pyod`, `hnswlib`, `shap`, `lime`, và manifest của lưới test ghi lúc chạy có thay đổi chưa commit (`is_dirty: true`).
- **Chưa có mã băm (sha256) của dữ liệu interim.** Hiện chỉ kiểm được bằng số file và số dòng (mục 9.1).

10. Đối chiếu tiêu chí hoàn thành (đề cương mục 4.1)

#	Hạng mục	Trạng thái	Bằng chứng / việc còn lại
1	Tính tái lập	Một phần	Có lệnh duy nhất và seed cố định (mục 9). Chưa chạy trên máy sạch; LOF chỉ tái lập ở mức trung bình
2	Pipeline dữ liệu	Đạt	Mục 2.3–2.4; `main.py`, ghi log, quyết định làm sạch kèm lý do
3	Bộ đặc trưng	Đạt	41 core (22 dùng trong benchmark); tên, công thức, kiểu và ý nghĩa của 22 đặc trưng ở Phụ lục A, đủ 41 trong schema; unit test
4	Bảng benchmark	Đạt	Bảng 4.1: 3 mô hình × 3–6 cấu hình × 5 seed, mean ± std; bảng 4.2 trên test
5	Bộ chỉ số	Đạt	Bảng 4.2: PR-AUC, ROC-AUC, P@10/50/100, recall tại ngân sách, tỷ lệ cảnh báo, thời gian fit/chấm
6	Baseline	Đạt	Ngẫu nhiên và luật số lần thất bại (cùng z-score, luật 6 điều kiện) trong mọi bảng
7	Phân tích lỗi	Một phần	Phân tích theo kịch bản xong (mục 4.4, 5.5). Review top 50 bộ 22 đặc trưng chờ hai người chấm và κ (mục 6)
8	Báo cáo kỹ thuật	Đạt	Tài liệu này
9	Chất lượng mã	Một phần	Cấu trúc thư mục, cấu hình tách rời, 258 test. Chờ review chéo và mentor duyệt
10	Nghiệm thu	Chưa	Chờ buổi demo; mô hình demo đã sẵn sàng (mục 9.4)

Phụ lục A: 22 đặc trưng của benchmark cuối

Một dòng là một tài khoản trong một ngày. "7 ngày trước" là 7 ngày lịch t−7 … t−1. Cột "NULL khi" ghi trường hợp đặc trưng không có giá trị; khi đó mô hình điền bằng trung vị của train (mục 3.2).

Nhóm	Đặc trưng	Kiểu	Công thức	Ý nghĩa hành vi	NULL khi
failure	`failure_ratio`	số thực	số lần thất bại (4625) / tổng số lần đăng nhập trong ngày	Tỷ lệ đăng nhập thất bại trong ngày	–
failure	`failure_locked_out_share`	số thực	số lần thất bại có lý do "account locked out" / số lần thất bại	Tỷ phần thất bại do tài khoản bị khoá (dấu hiệu dò mật khẩu)	không có lần thất bại nào
failure	`delta_mean_share_fail_7d`	số thực	tỷ lệ thất bại hôm nay − trung bình tỷ lệ thất bại của 7 ngày trước	Tỷ lệ thất bại tăng bất thường so với chính tài khoản	7 ngày đầu dữ liệu, hoặc 7 ngày trước không hoạt động
failure	`novelty_fail_host_7d`	số thực	số máy đích (`LogHost`) bị đăng nhập thất bại hôm nay mà không có trong 7 ngày trước	Thất bại ở những máy chưa từng thử	–
failure	`novelty_fail_failreason_7d`	số thực	số lý do thất bại hôm nay không có trong 7 ngày trước	Kiểu thất bại mới (ví dụ sai mật khẩu, tài khoản không tồn tại)	–
time	`activity_peak_hour_cos`	số thực	$\cos(2\pi \cdot h / 24)$, với h là giờ có nhiều sự kiện nhất trong ngày	Giờ cao điểm trong ngày, mã hoá vòng tròn để 23h và 0h nằm cạnh nhau	–
time	`hour_entropy`	số thực	entropy của phân bố sự kiện theo giờ / ln(số giờ có sự kiện)	Hoạt động dồn vào ít giờ (gần 0) hay trải đều (gần 1)	–
time	`dist_shift_hour_7d`	số thực	$\frac{1}{2} \cdot \Sigma$ |tỷ phần sự kiện ở giờ h hôm nay − tỷ phần ở giờ h của 7 ngày trước|	Phân bố giờ hoạt động thay đổi bao nhiêu so với tuần trước (0 là y hệt, 1 là khác hẳn)	chưa có lịch sử 7 ngày
time	`jaccard_hour_7d`	số thực	|giờ hoạt động hôm nay ∩ của 7 ngày trước| / |hợp của hai tập|	Độ trùng tập giờ hoạt động với tuần trước	chưa có lịch sử 7 ngày
time	`delta_mean_share_night_7d`	số thực	tỷ lệ sự kiện ngoài giờ (18h–7h) hôm nay − trung bình của 7 ngày trước	Hoạt động dời sang ban đêm so với chính tài khoản	7 ngày đầu dữ liệu
logon_type	`interactive_ratio`	số thực	số lần đăng nhập loại 2 (tương tác) / tổng số lần đăng nhập	Tỷ lệ đăng nhập trực tiếp tại máy	–
logon_type	`ntlm_ratio`	số thực	số lần dùng gói xác thực NTLM / tổng số lần đăng nhập	Tỷ lệ xác thực NTLM (giao thức cũ, hay gặp trong tấn công)	–
logon_type	`dist_shift_logontype_7d`	số thực	như `dist_shift_hour_7d`, nhưng theo loại đăng nhập thay cho giờ	Cơ cấu loại đăng nhập thay đổi so với tuần trước	chưa có lịch sử 7 ngày
logon_type	`novelty_logontype_7d`	số thực	số loại đăng nhập hôm nay không có trong 7 ngày trước	Dùng loại đăng nhập chưa từng dùng	–
fanout	`distinct_sources_count`	số nguyên	số máy nguồn (`Source`) khác nhau trong ngày	Đăng nhập từ bao nhiêu máy	–
fanout	`delta_mean_distinct_source_7d`	số thực	log(số máy nguồn hôm nay) − trung bình của 7 ngày trước	Số máy nguồn tăng bất thường so với chính tài khoản	7 ngày đầu dữ liệu
fanout	`peer_z_distinct_source`	số thực	(log số máy nguồn − trung vị của các tài khoản cùng loại trong ngày) / (IQR / 1,349), chặn trong ±10	Số máy nguồn cao bất thường so với các tài khoản cùng loại	–
novelty	`new_source_count_7d`	số nguyên	số máy nguồn hôm nay không có trong 7 ngày trước	Đăng nhập từ máy mới	–
novelty	`days_since_last_activity`	số nguyên	t − ngày hoạt động gần nhất trước t	Tài khoản nghỉ bao lâu trước hôm nay	lần hoạt động đầu tiên của tài khoản

Nhóm	Đặc trưng	Kiểu	Công thức	Ý nghĩa hành vi	NULL khi
novelty	`jaccard_source_7d`	số thực	|máy nguồn hôm nay ∩ của 7 ngày trước| / |hợp của hai tập|	Độ trùng tập máy nguồn với tuần trước	chưa có lịch sử 7 ngày
novelty	`novelty_share_pair_7d`	số thực	số sự kiện qua cặp (máy nguồn, máy đích) mới / tổng số sự kiện	Tỷ phần đăng nhập đi theo đường mới	không có sự kiện có đủ nguồn và đích
volume	`delta_mean_count_7d`	số thực	log(số sự kiện hôm nay) − trung bình của 7 ngày trước	Khối lượng tăng hoặc giảm bất thường so với chính tài khoản	7 ngày đầu dữ liệu

19 đặc trưng bị bỏ: 4 rhythm (`interarrival_dt_mean`, `delta_t_cv`, `same_second_share`, `is_single_event`) và `activity_peak_hour_sin`, `log_distinct_hosts`, `missing_source_ratio`, `dst_host_entropy`, `log_total_logons`, `custom_proc_share`, `delta_mean_distinct_pair_7d`, `new_host_count_7d`, `peer_z_share_night`, `rare_logon_type_count_log`, `remote_logon_ratio`, `volume_robust_z_7d`, `off_hours_ratio`, `delta_mean_distinct_fail_host_7d`, `jaccard_logontype_7d`. Công thức đầy đủ của cả 41 đặc trưng: `configs/feature_schema.yaml` và README mục 4.

Phụ lục B: bản đồ số liệu

Nội dung	Đường dẫn
Đề cương	`docs/Tong quan de tai ueba.md`
Từ điển dữ liệu, quyết định làm sạch	`docs/data_dictionary.md`, `docs/nhat_ky_trien_khai_pipeline.md`
Phân loại tài khoản	`docs/reports/thong_ke_loai_tai_khoan.md`
Bộ đặc trưng v4	`docs/reports/bao_cao_bo_dac_trung_v4.md`, `configs/feature_schema.yaml`
Bộ tiêm	`docs/huong_dan_tiem_bat_thuong_tuan4.md`, `configs/injection.yaml`, `src/injection/`
Baseline	`reports/week4/baselines_report.md`, `configs/baselines.yaml`
Lưới dev / test (22 đặc trưng)	`experiments/grid/dev_22f/`, `experiments/grid/test_22f/`, `experiments/grid/test_22f_nc1000/`
Lưới 41 đặc trưng (tuần 4)	`experiments/grid/dev/`, `experiments/grid/test/`, `reports/week4/tom_tat_tuan4.md`
Theo kịch bản, SHAP, ablation, chọn K	`reports/week5/` (`bao_cao_tuan5.md` và các file chi tiết), `experiments/analysis/`, `experiments/ablation/`
Review top 50	`experiments/analysis/review_top50_22f/` (chưa chấm)
Nhật ký thí nghiệm	`experiments/logs/experiment_log.csv`